






**การวิเคราะห์ประสิทธิภาพกระบวนการ
ยุติธรรมระดับเขตในประเทศอินเดียด้วย
เทคนิคการจัดกลุ่ม K-MEANS และการ
จำแนกประเภทด้วยจำลองตัดสินใจ**



สมาชิก




1. นายศิวัช คนขยัน (Data Analyst / Data Engineer): รับผิดชอบการทำความสะอาดข้อมูล (Data Cleaning), เตรียมข้อมูล (Data Preparation), วิเคราะห์ข้อมูล และสรุปผลโมเดล
2. นางสาวอัญปรีญา งามสวย (Documentation Lead): รับผิดชอบรายงาน Process Report, สไลด์, บันทึกการประชุม และ Contribution Log
3. นายณัฐพงศ์ ไชยพูน (Visualization): รับผิดชอบ Power BI และเว็บไซต์



ภาพรวมชุดข้อมูล (Dataset Overview)

- แหล่งข้อมูล: Kaggle – Indian Crimes Dataset (ขนาด 30,000 แถว, 10 คอลัมน์)
- ขอบเขต: ครอบคลุมข้อมูลอาชญากรรม 12 รัฐ, 300 เขต, 10 ประเภทอาชญากรรม ช่วงปี ค.ศ. 2014–2023
- คุณภาพข้อมูล: ไม่มีค่าที่สูญหาย (Missing values = 0) และไม่มีข้อมูลซ้ำ (Duplicate rows = 0)



Business Understanding

เป้าหมาย: ศึกษารูปแบบ/การกระจายของอาชญากรรมตามพื้นที่และเวลา, จัดกลุ่มข้อมูลลักษณะใกล้เคียงกัน, นำเสนอผลแบบ interactive

โจทย์วิเคราะห์ 3 ข้อ: (1) การกระจายอาชญากรรมตามประเภท/พื้นที่
(2) แนวโน้มจำนวนคดีตามเวลา
(3) การจัดกลุ่มพื้นที่ตามจำนวนคดี อัตราอาชญากรรม และดัชนียุติธรรม



DATA UNDERSTANDING

โครงสร้างตัวแปร

- ข้อมูลเชิงหมวดหมู่ Categorical (3): State, District, Crime_Type
- ข้อมูลเชิงตัวเลข Numerical (7): Year, Cases_Reported, Chargesheeted, Convictions, Population, Crime_Rate_per_100k, Justice_index

รายการตรวจสอบ	Raw CSV
จำนวนแถว	30,000
จำนวนคอลัมน์	10
จำนวนรัฐ	12
จำนวน District	300
จำนวนประเภทอาชญากรรม	10
Missing values	0
Duplicate rows	0
ความละเอียด Justice_index	ทศนิยม 2 ตำแหน่ง

DATA PREPARATION

ตรวจสอบข้อมูล 30,000 แถว 10 คอลัมน์ ไม่พบ Missing Values และ Duplicate Rows จึงไม่มีการลบแถวออก ก่อนทำ K-means ได้แปลงตัวแปรดิบให้เป็นอัตราส่วน 2 ค่า ได้แก่ Chargesheet_Rate และ Conviction_Rate พร้อมคำนวณ Justice_Index และ Crime_Rate_per_100k จากนั้นนำทั้ง 4 ตัวแปรมาทำ Normalization ให้อยู่ในช่วง 0-1 เพื่อให้มีอิทธิพลต่อการจัดกลุ่มอย่างเท่าเทียมกัน

BEFORE-AFTER ของการทำความสะอาดข้อมูล

รายการตรวจสอบ	ไฟล์ดิบ	หลังตรวจสอบ/เตรียมข้อมูล
จำนวนแถว	30,000	30,000
จำนวนคอลัมน์	10	10
Missing values	0	0
Duplicate rows	0	0
ชนิดข้อมูล	มีทั้งข้อความและตัวเลข	ตรวจสอบและกำหนดบทบาทตัวแปรตามชนิดข้อมูล
สร้างตัวแปรใหม่	-	สร้าง Chargesheet_Rate, Conviction_Rate, Justice_Index, Crime_Rate_per_100k
การเตรียมสำหรับ K-means	ค่าต่างหน่วย	Standardization เฉพาะตัวแปรที่ใช้ทำ clustering

MODEL SELECTION & VALIDATION

ในการศึกษาี้เลือกใช้ K-MEANS CLUSTERING สำหรับจัดกลุ่มข้อมูล เนื่องจากชุดข้อมูลไม่มีตัวแปรเป้าหมาย และต้องการค้นหากลุ่มข้อมูลที่มีลักษณะใกล้เคียงกัน โดยใช้ตัวแปรเชิงตัวเลข ได้แก่ CASES_REPORTED, CHARGESHEETED, CONVICTIONS, CRIME_RATE_PER_100K และ JUSTICE_INDEX ซึ่งผ่านการปรับสเกลก่อนนำมาวิเคราะห์ จากนั้นทดลองกำหนดจำนวนกลุ่มตั้งแต่ 2 ถึง 8 กลุ่ม และใช้ ELBOW METHOD เพื่อพิจารณาจำนวนกลุ่มที่เหมาะสม โดยดูจากจุดที่การเพิ่มจำนวนกลุ่มทำให้ระยะห่างภายในกลุ่มลดลงน้อยลงอย่างชัดเจน ผลการจัดกลุ่มที่ได้สามารถนำไปวิเคราะห์ลักษณะของแต่ละกลุ่มและแสดงผลผ่าน DASHBOARD เพื่อให้เห็นความแตกต่างของข้อมูลได้ชัดเจนยิ่งขึ้น

k	Avg. within-cluster distance
2	-2.8273
3	-2.1314
4	-1.7755
5	-1.5736
6	-1.3757
7	-1.2738
8	-1.147

MODEL SELECTION & VALIDATION

จากผลการทดสอบด้วย ELBOW METHOD พบว่าหลังจาก $K = 4$ อัตราการลดลงของค่า METRIC เริ่มลดลงอย่างชัดเจน จึงเลือกใช้ $K = 4$ เป็นจำนวนกลุ่มที่เหมาะสมสำหรับการวิเคราะห์ จากนั้นนำผลการจัดกลุ่มที่ได้จาก K-MEANS มาใช้เป็น LABEL เพื่อสร้างโมเดลจำแนกประเภทสำหรับตรวจสอบความชัดเจนของการแบ่งกลุ่ม โดยเปรียบเทียบประสิทธิภาพระหว่าง DECISION TREE และ RANDOM FOREST

โมเดล	Accuracy
Decision Tree	95.81% (+/- 0.42%)
Random Forest	92.42% (+/- 0.90%)

ผลการทดสอบพบว่า DECISION TREE ให้ค่า ACCURACY สูงกว่า RANDOM FOREST และมีค่า PRECISION และ RECALL ของแต่ละ CLUSTER สูงกว่าในเกือบทุกกลุ่ม แสดงให้เห็นว่ากลุ่มข้อมูลที่ได้จาก K-MEANS มีลักษณะแตกต่างกันค่อนข้างชัดเจน โดยในชุดข้อมูลนี้ DECISION TREE สามารถจำแนกกลุ่มได้แม่นยำกว่า RANDOM FOREST แม้จะเป็นโมเดลที่มีโครงสร้างซับซ้อนน้อยกว่า

Evaluation

เลือกใช้ K-means เพราะข้อมูลไม่มีตัวแปรเป้าหมายและต้องการสำรวจกลุ่มที่มีลักษณะคล้ายกัน โดยใช้ตัวแปร Cases_Reported, Chargesheeted, Convictions, Crime_Rate_per_100k และ Justice_index ทดสอบ $k = 2-8$ ด้วย Elbow Method (ดูจุดที่ Avg. within-cluster distance เริ่มลดลงช้าลงอย่างชัดเจน แทนการเลือกค่าที่ดีที่สุดจริงๆ) พบว่าจุดที่เหมาะสมคือ $k = 4$



Deployment / Visualization

- D3.js – ใช้เป็นตัวหลัก เพราะควบคุมรูปแบบกราฟและ interaction ได้ละเอียดกว่า
- Chart.js – ใช้เป็นตัวเปรียบเทียบ เพื่อดูความสะดวกในการพัฒนาและการสร้างกราฟมาตรฐาน

องค์ประกอบหลักของ Dashboard


1. ตัวกรองข้อมูล – State, District, Year, Crime Type
2. กราฟแนวโน้มจำนวนคดีตามช่วงเวลา
3. กราฟเปรียบเทียบระหว่างประเภทอาชญากรรม
4. แผนภูมิแสดงผลการจัดกลุ่มจาก K-means
5. Tooltip แสดงรายละเอียดเมื่อเลื่อนเมาส์ชี้ข้อมูล



เปรียบเทียบ D3.js กับ Chart.js


จุดแข็งของแต่ละตัว

- D3.js v7: ควบคุมได้ละเอียดทุกส่วน ไลบรารีเล็ก (~93 KB) วาดกราฟเร็ว ปรับแต่งเฉพาะทางได้ไม่จำกัด แต่ต้องเขียนเอง ทั้งแกน, tooltip, legend, แอนิเมชัน – เรียนรู้ยากและใช้เวลาพัฒนามานานกว่า (348 บรรทัด)
- ECharts 5: พัฒนาเร็วกว่าด้วย option object (265 บรรทัด) มี tooltip/legend/แอนิเมชัน/แผนที่ในตัว เรียนรู้ง่าย แต่ไลบรารีใหญ่กว่า (~334 KB) และวาดใหม่ช้ากว่าเมื่อเปลี่ยนตัวกรอง



เปรียบเทียบ D3.js กับ Chart.js

ประเด็น	D3.js	ECharts	ผู้ชนะ
บรรทัดโค้ด	348	265	ECharts
ขนาดไลบรารี	~93 KB	~334 KB	D3.js
เวลาวาดใหม่ (median)	~42 ms	~130 ms	D3.js
Tooltip/ แอนิเมชัน/แผนที่	เขียนเอง	มีในตัว	ECharts
ความยืดหยุ่น	ไม่จำกัด	จำกัดตาม option	D3.js
ความง่ายในการเรียนรู้	ยาก	ง่าย	ECharts



DATA DICTIONARY

Column	คำอธิบาย	ประเภท	นำไปใช้
State	รัฐของอินเดีย	Categorical	เปรียบเทียบพื้นที่
District	เขต/อำเภอ	Categorical	วิเคราะห์ระดับพื้นที่
Year	ปีที่รายงาน	Numerical	วิเคราะห์แนวโน้มเวลา
Crime_Type	ประเภทอาชญากรรม	Categorical	จำแนกประเภท
Cases_Reported	จำนวนคดีที่รายงาน	Numerical	ตัวแปรวิเคราะห์หลัก
Chargesheeted	จำนวนคดีที่จัดทำเอกสารกล่าวหา	Numerical	วิเคราะห์กระบวนการดำเนินคดี
Convictions	จำนวนคดีที่พิพากษาผิด	Numerical	วิเคราะห์ผลลัพธ์กระบวนการยุติธรรม
Population	จำนวนประชากร	Numerical	บริบทเปรียบเทียบพื้นที่
Crime_Rate_per_100k	อัตราอาชญากรรมต่อประชากรแสนคน	Numerical	วัดระดับอาชญากรรมเปรียบเทียบพื้นที่
Justice_index	ดัชนีสะท้อนกระบวนการยุติธรรม	Numerical	ประกอบการจัดกลุ่ม/ตีความ





ปัญหาที่พบและวิธีแก้ไข

พบปัญหาหลัก 5 ข้อระหว่างทำโปรเจกต์ พร้อมวิธีการจัดการ ดังนี้

1. ข้อมูลหลายชนิด/หลายหน่วย – เสี่ยงให้ตัวแปรค่าขนาดใหญ่ครอบงำการจัดกลุ่ม
→ แก้ด้วยการแยก Categorical/Numerical ออกจากกัน แล้วทำ Standardization ก่อนเข้า K-means
2. ไม่พบ Missing values/ข้อมูลซ้ำ – เสี่ยงเข้าใจผิดว่าต้องแก้ไขข้อมูลทั้งที่ไม่มีจุดบกพร่อง
→ เก็บหลักฐานผลตรวจสอบ (0 ค่า) ไว้เป็นหลักฐาน และไม่แก้ไขข้อมูลโดยไม่จำเป็น
3. การเลือกจำนวนกลุ่ม k ของ K-means – แต่ละค่า k ให้ผลตีความต่างกัน
→ ทดสอบหลายค่า k แล้วใช้ Elbow Method ดูกราฟ Avg. within-cluster distance จนได้ค่าที่เหมาะสมคือ $k = 4$
4. การทำ Visualization ให้ตรงใจ – กราฟเยอะเกินไปอาจทำให้ Dashboard ชับซ้อน
→ เลือกกราฟตามคำถามวิจัยที่ตั้งไว้ และเพิ่มตัวกรองเท่าที่จำเป็นเท่านั้น
5. ความแตกต่างระหว่าง D3.js กับ Plotly.js – แนวทางเขียนโค้ดและการควบคุมต่างกัน
→ แบ่งให้สมาชิกแต่ละคนลองทั้งสองเครื่องมือ แล้วบันทึกผลเปรียบเทียบไว้





SCENE - DO NOT CROSS - CRIME SCENE

DO NOT CROSS - CRIME SCENE

THANK YOU

Q&A



SCENE - DO NOT CROSS

DO NOT CROSS - CRIME SCENE - DO NOT CROSS - CRIME SCENE